

AgroVision

07 - XAI e Grad-CAM

Selvaraju et al. (2017) e referencias científicas

TCC-Docs · Material de estudo
Luiz Carlos Junior & Equipe AgroVision
Maio de 2026

1. O que é XAI

Explainable Artificial Intelligence (XAI) é um sub-campo da IA dedicado a tornar as decisões de modelos de aprendizado de máquina compreensíveis para humanos. O problema surge porque redes neurais profundas têm milhões de parâmetros que interagem de forma não-linear — e impossível inferir o comportamento do modelo apenas olhando seus pesos.

Adadi & Berrada (2018) sintetizam três perguntas centrais que XAI busca responder: (1) Por que o modelo decidiu desse jeito? (2) Como ele decidiria diferente? (3) Quando ele erra sistematicamente? O AgroVision foca na pergunta (1) usando uma técnica gradient-based.

2. Taxonomia das técnicas XAI

Dimensão	Opções	Onde o Grad-CAM se encaixa
Tempo	Intrínseca / Post-hoc	Post-hoc (aplicada depois do treino)
Escopo	Global / Local	Local (uma predição por vez)
Generalidade	Específico / Agnóstico	Específico (só funciona em CNNs)
Base	Gradient / Perturbation / Attention	Gradient-based

3. CAM — precursor (Zhou et al., 2016)

Class Activation Mapping: a ideia original. Funcionava apenas para arquiteturas que terminavam em Global Average Pooling (GAP) + Dense. Para uma classe c , o CAM é a média ponderada das ativações da última camada conv pelos pesos do Dense correspondentes a c .

$$\text{CAM} = \sum_k w_k^c \cdot A^k$$

Limitação: não funcionava em redes sem GAP no final, como VGG ou redes com fully-connected layers.

4. Grad-CAM — generalização (Selvaraju et al., 2017)

Selvaraju et al., no paper publicado no ICCV 2017, propuseram substituir os pesos do Dense (que só existem em arquiteturas com GAP no final) pelos **gradientes do score da classe em relação aos feature maps**. Isso torna a técnica aplicável a qualquer CNN, independente da arquitetura terminal.

$$\alpha_k^c = (1/Z) \sum_i \sum_j (\partial y^c / \partial A^k(i,j))$$

$$L_{\text{GradCAM}}^c = \text{ReLU}(\sum_k \alpha_k^c \cdot A^k)$$

O ReLU descarta contribuições negativas (pixels que *reduziriam* a confiança da classe).

5. Por que escolhemos Grad-CAM e não outras técnicas

Tecnica	Forca	Por que nao no AgroVision
LIME	Model-agnostic, intuitiva	Lenta: faz milhares de perturbacoes por imagem
SHAP	Base teorica solida (Shapley)	Caro computacionalmente, melhor para tabular
RISE	Boa para black-box	Requer 4000+ forward passes — inviavel mobile
Integrated Gradients	Atribuicoes pixel-a-pixel	Mapas ruidosos em CNNs profundas
Grad-CAM	1 forward + 1 backward, rapido	Escolhido

6. Implementacao no projeto

Arquivo: `api/xai/gradcam.py`. Funcao principal: `generate_gradcam()`. Usa `tf.GradientTape()` para gravar o forward pass, extrai gradientes via `tape.gradient()`, faz pooling com `tf.reduce_mean`, combina com `tf.reduce_sum` + ReLU e normaliza. Camada-alvo padrao: **Conv_1** (ultima conv do MobileNetV2 antes do GAP), tamanho espacial 7x7. Upsample bilinear para 224x224 e depois para a resolucao original da imagem.

7. Referencias bibliograficas centrais

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618-626.

Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., & Torralba, A. (2016). Learning Deep Features for Discriminative Localization. *CVPR 2016*, 2921-2929.

Adadi, A., & Berrada, M. (2018). Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI). *IEEE Access*, 6, 52138-52160.

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier (LIME). *KDD 2016*.

Lundberg, S., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). *NeurIPS 2017*.